Especificação Técnica de Software: Sistema de Inteligência de Mercado e Análise de Vagas Baseada em Dados (Data-Driven Job Market Intelligence)

1 INTRODUÇÃO

A evolução da gestão de capital humano e o recrutamento estratégico têm demandado, cada vez mais, abordagens baseadas em evidências quantitativas. O conceito de *People Analytics*, quando expandido para a análise de mercado externo, exige a captura e o processamento de grandes volumes de dados dispersos em múltiplas fontes na web. O presente documento técnico tem como objetivo formalizar a especificação de requisitos, a modelagem de dados e a arquitetura de processos para o desenvolvimento de um Sistema de Extração, Transformação e Análise de Vagas de Emprego (Job Market Scraper & Analytics Dashboard).

Este projeto visa automatizar a coleta de informações públicas sobre oportunidades de trabalho no setor de Tecnologia da Informação (TI), consolidando dados fragmentados em um repositório estruturado que permita análises de tendências, mapeamento de competências (skills) e inteligência competitiva salarial. A complexidade inerente à captura de dados não estruturados na web (web scraping), somada à necessidade de normalização semântica e visualização gerencial, exige um rigoroso planejamento de engenharia de software e engenharia de dados.

O relatório detalha desde os requisitos funcionais de extração e processamento de linguagem natural (PLN) até as restrições não funcionais de desempenho e ética digital (respeito ao robots.txt), culminando na apresentação dos artefatos de modelagem de dados e processos de negócio, essenciais para o entendimento da arquitetura da solução proposta.

2 ESCOPO E OBJETIVOS DO PROJETO

O sistema proposto atua como um *pipeline* de engenharia de dados ponta a ponta (*End-to-End*), desenhado para operar de forma autônoma e resiliente. O núcleo da solução reside na capacidade de transformar HTML bruto, proveniente de portais de emprego, em *insights* estruturados sobre o mercado de trabalho brasileiro.

2.1 Visão Geral da Solução

A arquitetura do sistema é modular, composta por subsistemas distintos que interagem de

forma assíncrona:

1. **Subsistema de Coleta (Web Scraping):** Responsável pela navegação automatizada e extração de dados brutos.
2. **Subsistema de Processamento (ETL & NLP):** Responsável pela limpeza, normalização e enriquecimento semântico dos dados, utilizando técnicas de Processamento de Linguagem Natural para identificar tecnologias e ferramentas nas descrições textuais.
3. **Subsistema de Armazenamento:** Um banco de dados híbrido (Relacional + JSONB) projetado para suportar consultas analíticas complexas.
4. **Subsistema de Visualização (Dashboard):** Interface de usuário para exploração de dados e geração de inteligência de mercado.

2.2 Justificativa Técnica e de Negócio

A volatilidade das tecnologias no setor de TI cria uma lacuna de informação entre o que as empresas buscam e o que os profissionais oferecem. Portais de vagas tradicionais oferecem busca, mas raramente oferecem análise agregada. Este sistema preenche essa lacuna ao permitir responder perguntas como: "Quais frameworks JavaScript estão em ascensão em São Paulo?", "Qual a média salarial para Arquitetos de Soluções em regime remoto?", ou "Quais benefícios são mais comuns em startups versus grandes corporações?". A automação deste processo, regida pelas Regras de Negócio (RN) aqui especificadas, garante que a tomada de decisão seja baseada em dados frescos (D-1), eliminando a dependência de relatórios de mercado estáticos e defasados.

3 ESPECIFICAÇÃO DE REQUISITOS DE SOFTWARE

A seção a seguir detalha os requisitos do sistema, classificados conforme a taxonomia padrão de Engenharia de Requisitos: Funcionais (o que o sistema faz), Não Funcionais (como o sistema se comporta) e Regras de Negócio (restrições operacionais). A redação e a organização seguem a lógica de numeração progressiva da NBR 6024, facilitando a referência cruzada durante as fases de desenvolvimento e teste.[1]

3.1 Requisitos Funcionais (RF)

Os requisitos funcionais descrevem as interações e funções específicas que o software deve executar. Eles foram subdivididos em módulos lógicos para melhor organização da arquitetura.

3.1.1 Módulo de Extração de Dados (Web Scraping)

Este módulo é a porta de entrada dos dados e deve lidar com a heterogeneidade das fontes web.

- **RF-001:** O sistema deve extrair os seguintes campos de dados da página de listagem de vagas: título da vaga, nome da empresa, localização e URL de detalhe da vaga.

    - *Análise Técnica:* A extração em nível de listagem é crítica para a performance, pois permite filtrar vagas irrelevantes antes de acessar a página de detalhes, economizando largura de banda e tempo de processamento. A "URL de detalhe" servirá como chave única primária para evitar duplicidade na fase de coleta inicial.
- **RF-002:** O sistema deve navegar até a URL de detalhe de cada vaga e extrair a descrição completa do cargo.
    - *Análise Técnica:* A descrição completa é, frequentemente, um texto não estruturado (BLOB/Text) contendo informações vitais (skills, benefícios) que não estão presentes nos metadados da listagem. Este requisito implica uma segunda camada de requisições HTTP (request/response cycle).
- **RF-003:** O sistema deve implementar lógicas para lidar com diferentes tipos de paginação nos sites-alvo, incluindo:
    - Paginação baseada em parâmetros de URL (ex: ?page=2).
    - Navegação por botões "Próximo" ou "Carregar Mais".
    - Rolagem infinita (*Infinite Scrolling*) que carrega conteúdo via JavaScript.
    - *Análise Técnica:* Este é um requisito de alta complexidade. A paginação via URL é trivial (iterativa), mas a rolagem infinita exige um navegador *headless* (como Selenium ou Puppeteer) para simular eventos de *scroll* e aguardar o carregamento do DOM (Document Object Model) via AJAX, impactando a arquitetura do *crawler* (necessidade de driver de navegador vs. requisições puras).

3.1.2 Módulo de Transformação e Carga (ETL)

Após a extração, os dados brutos (Raw Data) devem ser higienizados e estruturados.

- **RF-004:** O sistema deve analisar o conteúdo HTML bruto coletado para extrair os campos de dados definidos.
    - *Análise Técnica:* Implica o uso de *parsers* (ex: BeautifulSoup, lxml) para percorrer a árvore DOM e localizar nós específicos via XPATH ou seletores CSS. O sistema deve ser resiliente a pequenas mudanças no layout do HTML fonte.
- **RF-005:** O sistema deve limpar e normalizar os dados extraídos, incluindo a remoção de tags HTML, padronização de nomes de localidades (ex: "S. Paulo" para "São Paulo") e unificação de formatos de data.
    - *Análise Técnica:* A normalização é vital para a integridade referencial. "S. Paulo", "SP", "Sao Paulo" e "São Paulo" devem ser mapeados para uma única entidade geográfica no banco de dados (ver Modelagem de Dados).
- **RF-006:** O sistema deve carregar os dados processados em uma tabela no banco de dados.
    - *Análise Técnica:* Define o estágio de "Load" do ETL. A inserção deve respeitar as restrições de unicidade para evitar duplicatas (ver RN-006).
- **RF-007:** O sistema deve utilizar a biblioteca pandas para realizar a ingestão dos dados em lote no banco de dados.

- *Análise Técnica:* O uso de DataFrames do Pandas permite manipulação eficiente em memória e inserção em lote (*bulk insert*), reduzindo o *overhead* de transações de banco de dados individuais (commit único vs. múltiplos commits).

3.1.3 Módulo de Análise de Dados (PLN - Processamento de Linguagem Natural)

Este módulo agrega valor aos dados brutos, transformando texto livre em dados estruturados.

- **RF-008:** O sistema deve aplicar técnicas de Processamento de Linguagem Natural (PLN) para extrair habilidades técnicas (linguagens, frameworks, ferramentas) das descrições de vagas.
  - *Análise Técnica:* Requer tokenização e reconhecimento de entidades nomeadas (NER). Dada a especificidade do domínio (TI), modelos genéricos podem falhar, exigindo ajuste fino ou abordagens híbridas.
- **RF-009:** O sistema deve utilizar uma abordagem baseada em dicionário para identificar um conjunto predefinido de habilidades.
  - *Análise Técnica:* Uma abordagem determinística (Keyword Matching) é solicitada aqui para garantir precisão em termos técnicos conhecidos (ex: "Java", "Python", "AWS"), complementando o RF-008. Isso evita falsos negativos comuns em modelos probabilísticos.
- **RF-010:** O sistema deve armazenar as habilidades extraídas e normalizadas em uma tabela de banco de dados relacional, associando cada habilidade à sua respectiva vaga.
  - *Análise Técnica:* Isso dita a criação de uma tabela associativa (many-to-many) entre Vagas e Competencias (ver Seção de Modelagem de Dados), permitindo consultas como "Vagas que exigem Python E SQL".

3.1.4 Módulo de Visualização (Dashboard)

A interface final para o usuário de negócio.

- **RF-011:** O dashboard deve exibir indicadores chave de desempenho (KPIs), como o número total de vagas ativas.
- **RF-012:** O dashboard deve incluir um mapa de calor geográfico mostrando a distribuição de vagas pelo Brasil.
  - *Análise Técnica:* Depende diretamente da qualidade da normalização geográfica (RF-005) e pode exigir integração com APIs de geocodificação (Latitude/Longitude) se o banco não possuir dados espaciais nativos.
- **RF-013:** O dashboard deve fornecer filtros interativos para que o usuário possa segmentar os dados por: título do cargo, localização, nível de senioridade e modalidade (remoto, híbrido, presencial).
- **RF-014:** O dashboard deve exibir um gráfico de barras com as habilidades mais demandadas, de acordo com os filtros aplicados.
  - *Análise Técnica:* Exige consultas de agregação (GROUP BY, COUNT) dinâmicas sobre

a tabela associativa de competências gerada no RF-010.

- **RF-015:** O dashboard deve apresentar um gráfico de linhas para a análise temporal da demanda por tecnologias específicas.
  - *Análise Técnica:* Requer que o histórico de dados seja preservado (Série Temporal), utilizando o campo data_publicacao ou data_coleta como eixo temporal.

3.2 Requisitos Não Funcionais (RNF)

Os requisitos não funcionais definem os atributos de qualidade do sistema, essenciais para sua viabilidade técnica e operacional.

3.2.1 Desempenho e Eficiência

- **RNF-001:** A ingestão de dados no banco de dados deve ser otimizada para operações em lote, a fim de minimizar o tempo de carga.
  - *Contexto:* Em cenários de *Big Data*, inserções linha-a-linha são inviáveis. O uso de COPY (PostgreSQL) ou INSERT INTO... VALUES (...), (...) é mandatório.
- **RNF-002:** As consultas no dashboard devem ter um tempo de resposta rápido para garantir uma boa experiência do usuário.
  - *Contexto:* Implica a criação de índices adequados nas colunas de filtro (Localização, Título) e, possivelmente, o uso de *Materialized Views* para pré-calcular agregações pesadas.
- **RNF-003:** O web scraper deve incluir atrasos aleatórios entre as requisições para não sobrecarregar os servidores dos sites-alvo.
  - *Contexto:* Técnica de *Politeness* (educação de bots). Intervalos fixos são fáceis de detectar por firewalls (WAF). O atraso aleatório (ex: sleep(random(2, 5))) simula comportamento humano.

3.2.2 Confiabilidade e Robustez

- **RNF-004:** O sistema deve ter um mecanismo de alerta (ex: notificação por e-mail) para informar sobre falhas na execução da pipeline.
  - *Contexto:* Observabilidade. Falhas em scrapers são comuns (mudança de layout do site). O administrador deve ser notificado proativamente (Pattern: *Dead Letter Queue* ou *Alert Hook*).
- **RNF-005:** O scraper deve ser projetado com técnicas anti-detecção para minimizar o risco de bloqueios, incluindo rotação de User-Agents e uso de proxies.
  - *Contexto:* Muitos sites bloqueiam requisições sem cabeçalhos de navegador (Headless). A rotação de IPs (Proxies) e a spoofing de User-Agents são contramedidas padrão na indústria de coleta de dados.

3.2.3 Usabilidade e Manutenibilidade

- **RNF-006:** O código-fonte deve ser modular e bem documentado para facilitar a

manutenção e futuras extensões.
- **RNF-007:** O dashboard deve ter uma interface de usuário clara e intuitiva.

3.2.4 Segurança e Conformidade Legal

- **RNF-008:** O web scraper deve respeitar as diretivas do arquivo robots.txt dos sites-alvo.
  - *Contexto:* Requisito ético e legal fundamental. O robots.txt é o protocolo padrão da web para autorizar ou negar acesso a crawlers. Ignorá-lo pode acarretar bloqueio de IP e riscos jurídicos.
- **RNF-009:** O sistema não deve coletar ou armazenar dados pessoais sensíveis de candidatos.
  - *Contexto:* Conformidade com a LGPD (Lei Geral de Proteção de Dados). O foco é em dados públicos da vaga, não em dados de indivíduos.

3.3 Regras de Negócio (RN)

As regras de negócio definem as políticas e restrições que governam o domínio da aplicação.

- **RN-001:** A fonte de dados primária são os portais de emprego públicos com alto volume de vagas de TI no Brasil.
- **RN-002:** A coleta de dados só é permitida em sites cujo robots.txt e Termos de Serviço não proíbam explicitamente a atividade de scraping.
- **RN-003:** A atualização dos dados no banco de dados deve ocorrer diariamente para garantir que as análises de tendências sejam baseadas em informações recentes.
- **RN-004:** O esquema do banco de dados deve ser híbrido: campos-chave usados para filtragem e agregação (título, localização, modalidade) devem ser colunas relacionais, enquanto o restante dos dados variáveis deve ser armazenado em um campo do tipo JSONB para garantir flexibilidade e performance.
  - *Análise:* Esta regra dita a arquitetura de dados (PostgreSQL é ideal para suporte JSONB + Relacional). Permite que atributos novos (ex: "benefícios específicos") sejam capturados sem alteração de esquema (ALTER TABLE).
- **RN-005:** Uma habilidade é definida como qualquer tecnologia, ferramenta, framework, metodologia ou competência técnica explicitamente mencionada na descrição textual de uma vaga.
- **RN-006:** A URL de origem de cada vaga deve ser armazenada e tratada como um campo único (UNIQUE) no banco de dados para evitar a duplicação de registros.
  - *Análise:* Define a chave natural de deduplicação. Impede que a mesma vaga, coletada em dias consecutivos, infle as estatísticas.
- **RN-007:** Todo o processo, desde a coleta até a disponibilização dos dados para o dashboard, deve ser 100% automatizado, sem necessidade de intervenção manual para as execuções agendadas.

4 MODELAGEM DE DADOS

A modelagem de dados traduz os requisitos informacionais e as regras de negócio (especialmente RN-004 e RN-006) em uma estrutura lógica de armazenamento. Para este projeto, optou-se por um Modelo Entidade-Relacionamento (MER) que suporta alta integridade referencial para as dimensões de análise, combinada com flexibilidade para os atributos descritivos.

4.1 Estrutura do Banco de Dados Relacional

A análise do Diagrama de Entidade-Relacionamento (DER) fornecido (Imagem 1) revela uma arquitetura em estrela modificada, centrada na entidade vaga. A seguir, detalha-se a estrutura semântica e física de cada entidade modelada.

4.1.1 Entidade Central: Vaga

A tabela vaga é o núcleo do sistema, armazenando o fato principal: a existência de uma oportunidade de emprego.

- **Chave Primária (PK):** id. Identificador artificial único.
- **Chaves Estrangeiras (FK):**
  - empresa_id: Referencia a tabela empresa. Cardinalidade (0,n), indicando que uma vaga pertence a uma empresa, e uma empresa pode ter várias vagas.
  - localizacao_id: Referencia a tabela localizacao. Permite normalização geográfica.
  - fonte_id: Referencia a tabela fonte_dados. Rastreia a origem da informação (auditabilidade).
- **Atributos Descritivos:** titulo, modalidade (remoto/presencial), salario_base, data_coleta (fundamental para séries temporais), data_publicacao, descricao (texto completo), tipo_contrato (CLT/PJ), moeda.
- **Observação sobre RN-004:** Embora a imagem mostre colunas explícitas, a implementação física pode encapsular atributos voláteis em uma coluna metadata (JSONB) dentro desta tabela, mantendo titulo e salario como colunas indexadas para performance.

4.1.2 Entidades Dimensionais

As tabelas satélites normalizam os dados para evitar redundância e garantir consistência (ex: evitar grafias diferentes para a mesma cidade).

1. **Tabela empresa:** Armazena dados institucionais.
   - *Atributos:* id (PK), nome, endereco_sede, setor, tamanho, rating (avaliação da empresa, se disponível), website.
   - *Relação:* (1,1) com vaga. Uma vaga deve estar associada a uma empresa (mesmo que seja "Confidencial").

2. **Tabela localizacao:** Normaliza as coordenadas geográficas.
    - *Atributos:* id (PK), cidade, estado_uf, pais, regiao.
    - *Importância:* Facilita o atendimento ao RF-012 (Mapa de Calor). Ao invés de armazenar strings repetidas ("São Paulo", "São Paulo", "São Paulo"), armazena-se um ID, otimizando o armazenamento e a filtragem.
3. **Tabela fonte_dados:** Gerencia as origens do scraping.
    - *Atributos:* id (PK), nome_site, url_base.
    - *Relação:* Uma fonte pode prover muitas vagas (1,n).

4.1.3 Tabelas Associativas e Atributos Multivalorados

Como uma vaga pode exigir múltiplas competências e oferecer múltiplos benefícios, o modelo utiliza tabelas de junção (*Bridge Tables*) para resolver relacionamentos muitos-para-muitos (N:M).

1. **Tabela competencia e vaga_competencia:**
    - competencia: Dicionário de skills (ex: "Python", "SQL"). Atributos: id, nome, tipo.
    - vaga_competencia: Tabela pivô contendo apenas vaga_id (FK) e competencia_id (FK).
    - *Justificativa:* Atende aos RF-008 e RF-010. Permite contar quantas vezes a skill "Java" aparece em todo o banco de dados com uma única consulta SQL otimizada.
2. **Tabela beneficio e vaga_beneficio:**
    - Estrutura análoga à de competências, mapeando benefícios (ex: "Vale Refeição", "Gympass") para as vagas.

4.2 Diagrama Entidade-Relacionamento (DER)

A figura abaixo ilustra visualmente as tabelas, atributos e relacionamentos descritos acima. O diagrama segue a notação "Pé de Galinha" (Crow's Foot notation) para expressar as cardinalidades.

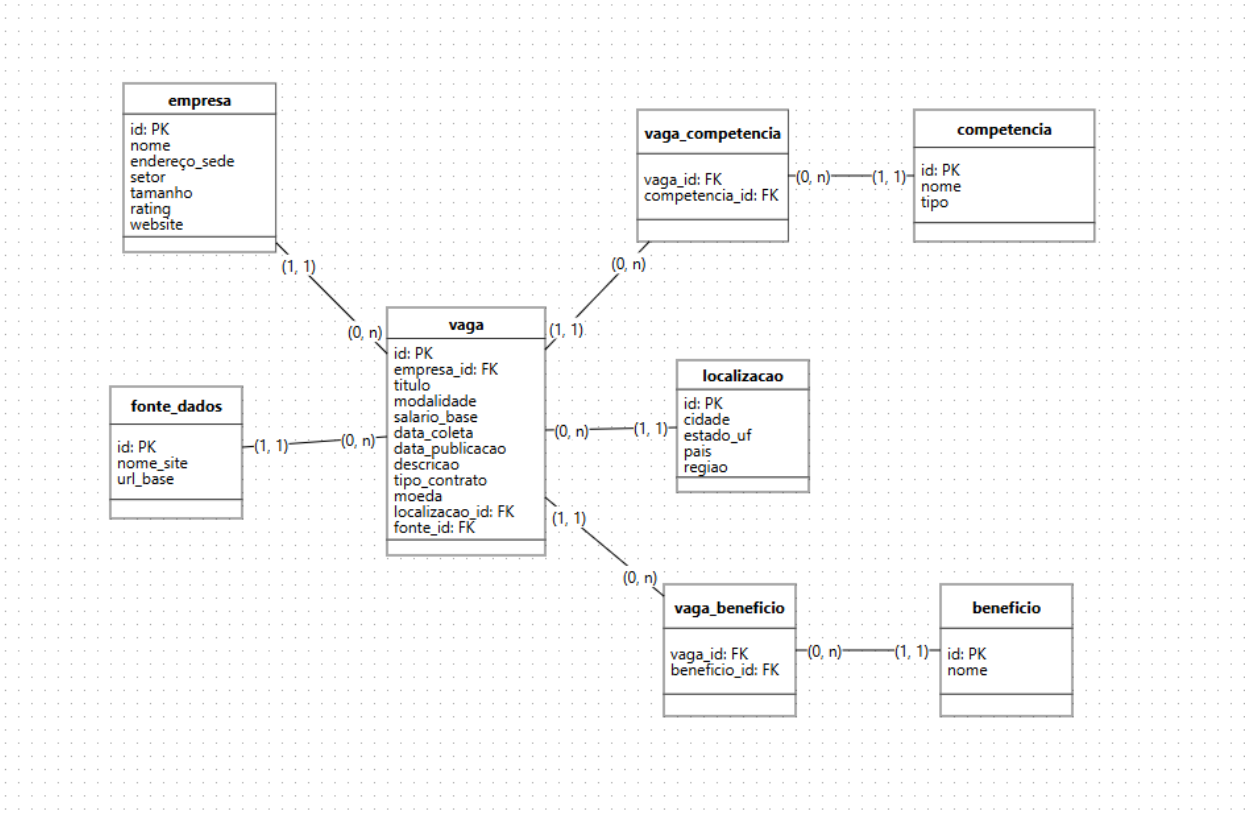

Figura 1 — Modelo Entidade-Relacionamento do Sistema de Vagas.
Fonte: Elaboração baseada na especificação do projeto.

A análise deste diagrama confirma a adesão à Terceira Forma Normal (3FN), pois todos os atributos não-chave dependem apenas da chave primária de suas respectivas tabelas, e não há dependências transitivas óbvias nas tabelas principais.

5 MODELAGEM DE PROCESSOS

A modelagem de processos descreve o fluxo dinâmico da informação, desde o agendamento da tarefa até a visualização no dashboard. Baseado no fluxograma fornecido (Imagem 2), detalhamos o *pipeline* de dados que implementa os requisitos funcionais e regras de negócio.

5.1 Fluxo de Engenharia de Dados (Pipeline ETL)

O processo é linear, orientado a eventos e desenhado para tolerância a falhas. A seguir, descreve-se cada etapa do fluxo apresentado na Imagem 2.

5.1.1 Inicialização e Extração (Ingestão)

1. **Início Agendado:** O processo é disparado por um agendador (ex: Cron job, Apache

Airflow) conforme RN-003 (diariamente).

2. **Web Scraping (RF-001, RF-002):** O bot inicia a navegação.
   - *Controle de Tráfego:* Aplicação de atrasos aleatórios e rotação de User-Agents (RNF-003, RNF-005) e verificação do robots.txt (RNF-008).
   - *Saída:* HTML bruto das páginas de listagem e detalhes.
3. **Extração de Dados Brutos:** O conteúdo relevante é segregado do código de formatação da página.

5.1.2 Transformação e Limpeza

1. **Transformação de Dados (RF-004, RF-005):**
   - Remoção de tags HTML (ex: <br>,).
   - Conversão de strings monetárias ("R$ 5.000,00") para float ou decimal.
   - Padronização de datas ("há 2 dias" -> 2023-10-25).
2. **Limpeza e Normalização (RF-007):** Uso de Pandas para deduplicação em memória e tratamento de valores nulos (NULL handling).

5.1.3 Carga e Validação (Load)

1. **Carga na Tabela 'Vagas' (RF-006):** Tentativa de inserção no banco de dados.
2. **Verificação de Duplicidade (Gateway de Decisão):**
   - O sistema verifica a unicidade da URL (RN-006).
   - *Caminho "Duplicado":* O registro é descartado/ignorado. Fluxo termina para este item.
   - *Caminho "Novo Registro":* O registro é persistido e o fluxo avança para o enriquecimento (PLN).

5.1.4 Enriquecimento Semântico (PLN)

Apenas para novos registros (otimização de recursos):

1. **Execução do Módulo PLN (RF-008):** O texto da descrição da vaga é processado.
2. **Extração de Habilidade (RF-009, RF-005):** Algoritmos de busca por dicionário ou modelos de linguagem identificam termos técnicos.
3. **Carga na Tabela 'Habilidade' (RF-010):** As skills identificadas são inseridas nas tabelas competencia e vaga_competencia.

5.1.5 Disponibilização

1. **Dados Prontos:** O banco de dados está atualizado e consistente.
2. **Dashboard Interativo (RF-011 a RF-014):** As ferramentas de BI leem os dados novos.
3. **Fim do Processo:** O ciclo se encerra, gerando logs de sucesso ou notificando falhas (RNF-004).

5.2 Diagrama de Fluxo de Processos

A Figura 2 ilustra este algoritmo, destacando os pontos de decisão e a sequência lógica de execução. A cor amarela indica configurações iniciais/RNFs, cinza representa etapas de processamento, o losango branco representa a decisão lógica crítica (duplicidade) e o verde/azul representam os estágios finais de valor para o usuário.

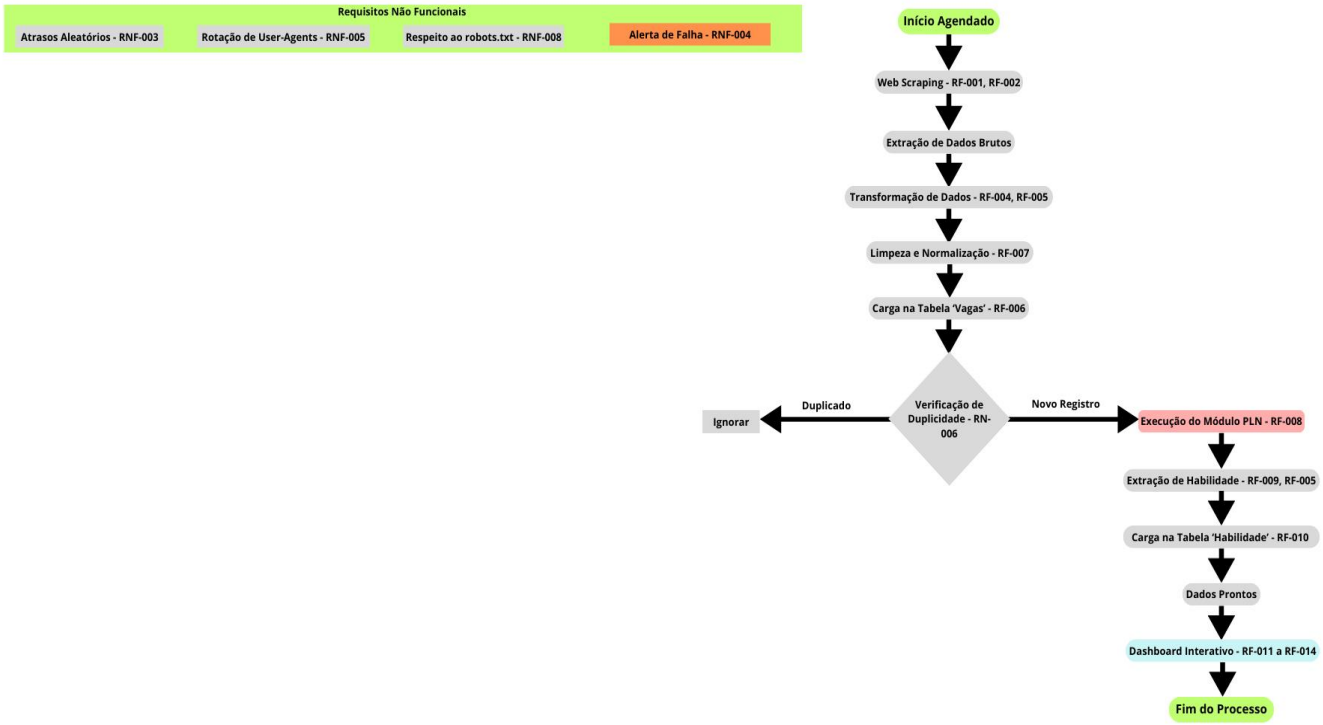

Figura 2 — Fluxograma do Pipeline de Coleta e Processamento de Dados.
Fonte: Elaboração baseada na especificação do projeto.

Este fluxo demonstra conformidade com a RN-007 (Automação 100%), pois não há etapas manuais representadas no diagrama; todas as decisões (ex: duplicado vs. novo) são baseadas em regras lógicas programáveis.